

2025年中国AIDC产业发展白皮书： 智算中心如何撑起大模型时代的蓝图？

China AIDC infrastructure Industry
中国のAIDCインフラ産業

概览标签：AIDC、大模型、智能算力

报告提供的任何内容（包括但不限于数据、文字、图表、图像等）均系头豹研究院独有的高度机密性文件（在报告中另行标明出处者除外）。未经头豹研究院事先书面许可，任何人不得以任何方式擅自复制、再造、传播、出版、引用、改编、汇编本报告内容，若有违反上述约定的行为发生，头豹研究院保留采取法律措施，追究相关人员责任的权利。头豹研究院开展的所有商业活动均使用“头豹研究院”或“头豹”的商号、商标，头豹研究院无任何前述名称之外的其他分支机构，也未授权或聘用其他任何第三方代表头豹研究院开展商业活动。

研究目的

揭示大模型从训练到推理的全生命周期技术范式，包括其资源高度密集的训练方法、追求极致效率的推理优化策略，以及模型厂商在开源与闭源路径下的差异化竞争格局；另一方面，深入探究支撑模型运行的AIDC基础设施，分析核心硬件的功耗演进如何引发数据中心在供电、散热及能效（PUE）等方面的系统性变革与核心挑战。

研究区域范围：中国及全球

研究对象：AIDC产业链全景

本报告的关键问题：

- 1) 大模型的训练与推理在技术流程、资源消耗和优化策略上有何本质区别？
- 2) 模型层的核心厂商在开源/闭源、MaaS平台等方面采取了哪些差异化竞争战略？
- 3) 从全球和中国的算力结构来看，“智算”规模超越“通算”反映了怎样的产业根本性转变？

摘要

- **市场关注点从模型性能向业务适配性转移**：大模型市场已从早期追求性能与价格的同质化竞争，演变为以业务场景适配为核心的价值驱动阶段。市场关注点不再是模型的绝对能力，而是能否在特定场景以最优性价比创造实际业务价值。这一趋势体现为分层化的应用策略：金融、医疗等高价值实时交互场景倾向于采用70B级旗舰模型以确保决策质量；文档分析等业务处理层普遍采用7B级精炼模型以平衡成本与效率；而在边缘设备端则部署1.5B级微型模型，以满足极致的响应速度要求。
- **从内卷转向差异化竞争**：大模型市场正告别初期追逐技术参数和低价的同质化竞争，全面转向以自身优势为核心的差异化战略新阶段。领先的厂商依托各自核心禀赋，已初步形成差异化路线，例如百度的“云智一体”全栈整合、阿里云的“MaaS”与开源生态、以及火山引擎的应用反哺技术模式，市场竞争的焦点已不再是单一的性能称王。
- **智算成为核心引擎，中美主导两极格局**：全球算力建设正从总量扩张转向结构跃迁，2023年全球智算力规模达到875 EFLOPS，首次超过基础算力，成为增长的主导引擎。在区域格局上，全球算力资源正加速向中美两国集中，2023年美国算力占全球41%，中国占31%，合计超过七成。尽管总量居次，但中国的智算力建设进展显著，占全球智能算力总规模的39%，反映出其在资源受限背景下优先发展AI基础设施的国家战略。
- **功耗激增倒逼制冷技术向液冷革新**：新一代AI芯片与服务器的功耗正急剧攀升，单服务器总功耗已突破14kW，给智算中心带来了严峻的电力和散热挑战。这导致全球及中国数据中心的PUE（能源使用效率）优化已进入结构性瓶颈期，传统风冷技术难以支撑高密度算力部署。因此，数据中心制冷技术正加速从传统风冷向液冷跃迁，后者已成为满足下一代智算中心能效控制目标的核心技术路径。

目录

CONTENTS

◆ 大模型产业模型训练层	-----	06
• 大模型训练全流程框架	-----	07
• 大模型预训练阶段的方法总览	-----	08
• 决定大模型预训练阶段成效的关键工具	-----	09
• 预训练阶段的核心价值	-----	10
• 后训练阶段流程	-----	11
• 后训练阶段流程核心技术汇总	-----	12
• 后训练阶段的核心价值	-----	13
• 大模型训练阶段的资源消耗	-----	14
◆ 大模型产业模型推理层	-----	15
• 大模型推理阶段流程框架	-----	16
• 大模型推理阶段主流参数	-----	17
• 大模型推理核心阶段	-----	18
• 大模型推理PD分离技术	-----	19
◆ 大模型产业基础大模型市场洞察	-----	20
• 基础大模型全景图谱	-----	21
• 基座大模型调用量规模	-----	22
• 基础大模型厂商竞争差异化路线初显	-----	23
• 大模型正从追逐顶尖性能向不同场景适配转移	-----	24

目录

CONTENTS

• 阿里云	-----	25
• 火山引擎	-----	26
• 百度智能云	-----	27
◆ 大模型产业AI基础设施层深度研究	-----	28
• 智算中心基础构成	-----	29
• GPU芯片功耗增加	-----	30
• 新服务器功耗增加	-----	31
• 成本影响因素分析	-----	32
• 智算中心的成本与能耗	-----	33
• 商业模式	-----	34
• 制冷技术PUE发展趋势	-----	35
• 供电系统	-----	36
• 中国投运/在建/规划智算中心项目区域分布	-----	37
• 智算中心参与者分布	-----	38
• 数据中心电力需求	-----	39
• 全球及中国数据中心平均年PUE	-----	40
◆ AIDC全球版图深度研究	-----	41
• 全球算力及智算建设规模	-----	42
• 中国算力建设现状	-----	43
• 行业算力需求	-----	46

目录

CONTENTS

• 美国算力建设现状	-----	47
• 欧洲算力建设现状	-----	49
• 亚太算力建设现状	-----	50
• 拉美算力建设现状	-----	51
• 中东算力建设现状	-----	52
◆ 头豹业务合作介绍	-----	53
◆ 方法论及法律声明	-----	54

第二章节：大模型训练层


主要观点：

- 大模型训练的全流程框架，是一个先通过预训练和监督微调构建模型的基础能力，再通过人类反馈强化学习完成关键价值对齐的系统性工程。大模型预训练阶段的核心方法是通过自回归语言建模学习海量文本的统计规律并引入任务提示以获得对特定任务的完成能力
- 大模型预训练的核心工具包括批量大小精细调控、学习率预热与衰减、AdamW优化以及正则化与梯度裁剪，旨在提高预训练阶段的效率、降低成本、保证稳定并加快收敛与泛化
- 预训练大模型的价值在于利用海量、多样化语料提取深度通用知识与语义表示，从而大幅提升微调效率与模型泛化能力，显著降低算力与开发成本
- 后训练流程包括监督微调、奖励模型训练与PPO强化学习，目的是通过融合人工偏好反馈与强化学习优化生成策略，以提升模型的对话质量、安全性和人类意图对齐度
- 大模型训练阶段消耗的资源主要集中在预训练阶段，需要数千至上万块GPU并行运算、处理千亿级至万亿级Token数据、耗时数周至数月，占总算力消耗的90-99%

大模型训练层——大模型训练全流程框架

大模型训练的全流程框架，是一个先通过预训练和监督微调构建模型的基础能力，再通过人类反馈强化学习完成关键价值对齐的系统性工程

大模型训练全流程框架



- ❑ 大模型的训练始于海量数据处理与预训练，目的是让模型从广泛的文本中学习世界知识与语言规律，从而构建出一个强大的基础模型。随后，模型进入监督微调阶段，通过高质量的人工标注问答数据进行训练，以学会理解并遵循人类的指令，初步成为一个具备对话能力的AI助手。
- ❑ 为使模型行为更安全并符合人类价值观，需要进行基于人类反馈的强化学习。该过程会先利用人工排序的模型回答，训练出一个能评估回答优劣的奖励模型。接着，这个奖励模型将作为“裁判”在强化学习中持续优化主模型，引导其产出更符合人类偏好的内容。经过这一系列精细的对齐，最终得到一个兼具强大能力与可靠价值观的最终模型。

大模型训练层——大模型预训练阶段的方法总览

大模型预训练阶段的核心方法是通过自回归语言建模学习海量文本的统计规律并引入任务提示以获得对特定任务的完成能力


大模型预训练阶段的方法总览

- 大模型预训练的本质是通过上文的词来预测下一个词，属于无监督的预训练。比如，给定一个无监督的语料：

$$U=\{u_1,\cdots,u_n\}$$

- 而预训练是要将这一方程最大化：

$$L(U)=\sum \log p(u_i \mid u_{i-k},\cdots,u_{i-1};\Theta)$$



- 在大语言模型的预训练阶段，也会引入情境学习 (In-context Learning) 的训练范式。为增强模型对任务指令的泛化理解能力，训练数据会被构建为特定格式：
- 输入序列通常包含一项任务描述，并附带若干上下文范例。例如，向模型输入：“请将中文翻译成英文。你好，Hello，再见，goodbye，销售，”，并训练其准确预测后续的正确文本“sell”。

Few-shot learning

允许输入数条示例和一则任务说明

One-shot learning

只允许输入一条示例和一则任务说明

Zero-shot learning

不允许输入任何范例，只允许输入一则任务说明

- 通过引入 in-context learning 技术，使得预训练的大语言模型直接拥有完成特定任务的能力


预训练阶段模型通过自回归语言建模从海量文本中学习统计规律。模型将每个词映射为连续向量，经过多层Transformer自注意力模块，依次预测下一个词，训练时最大化所有位置的预测准确度，使模型既能捕捉短期词汇搭配，也能掌握长程语义结构，为各类下游任务提供通用且强大的表征。

为了让模型在推理时无需额外微调即可完成新任务，预训练数据采用“任务说明 + 示例”格式化输入。输入多条示例加说明可实现少样本学习；输入单条示例加说明可实现单样本学习；仅输入任务说明可实现零样本学习。通过这种方式，模型学会根据提示在翻译、问答、分类等多种场景中直接给出准确结果。

大模型训练层——决定大模型预训练阶段成效的关键工具

大模型预训练的核心工具包括批量大小精细调控、学习率预热与衰减、AdamW优化以及正则化与梯度裁剪，旨在提高预训练阶段的效率、降低成本、保证稳定并加快收敛与泛化

决定大模型预训练阶段成效的关键技术维度



- ❑ 在大规模语言模型的预训练中，合理设置批量训练大小、精心设计学习率预热与衰减策略、选用经过验证的优化器（如AdamW）并配合恰当的正则化与梯度裁剪，是确保训练稳定性、收敛速度与最终模型性能的基石。
- ❑ 在此基础上，各大技术团队还广泛应用混合精度训练、激活检查点、流水线并行与张量并行架构、课程学习策略以及多样化预训练目标，诸如SpanBERT、BART和XLNet等，这些辅助技术旨在进一步降低计算开销、缩短训练周期并增强模型在大规模语料上的泛化能力。

大模型训练层——预训练阶段的核心价值

预训练大模型的价值在于利用海量、多样化语料提取深度通用知识与语义表示，从而大幅提升微调效率与模型泛化能力，显著降低算力与开发成本


大模型预训练阶段的核心价值

提高样本效率

- 时间成本：预训练-微调流程让开发者在短时间内建立高性能模型，避免了从头训练数周或数月的漫长等待。
- 经济成本：共享预训练模型减少了重复购买算力的需求，对于中小企业或研究团队尤其重要。

提升泛化能力

- 通过在多样化语料上预训练，模型学到的特征更具稳健性，能够更好地应对下游任务中的分布漂移与噪声。



预训练阶段的核心价值

降低开发成本

- 时间成本：预训练-微调流程让开发者在短时间内建立高性能模型，避免了从头训练数周或数月的漫长等待。
- 经济成本：共享预训练模型减少了重复购买算力的需求，对于中小企业或研究团队尤其重要。

支持快速迭代

- 预训练范式易于“持续预训练”，即在已有模型基础上不断融入新数据，让模型实时更新，维持对新知识的敏感度。

- 预训练模型通过大规模、多领域语料的自监督学习，提炼出深度语义表示与丰富通用知识。基于此基础，微调仅需少量任务数据即可快速适配专业场景，大幅提升样本利用率与收敛速度，增强模型稳健性。配合持续预训练策略，还能动态融入新兴数据，保持对领域演化和新知识的敏感响应。
- 从零训练不仅需投入万级 GPU 小时和月级迭代周期，还存在知识迁移门槛高、通识知识匮乏和性能瓶颈等难题。相比之下，预训练-微调方法可复用开源成果，显著降低硬件与开发成本，使中小团队也能实现与 GPT-3、PaLM 同级别的高性能表现。

从零到一构建大模型的痛点



资源消耗巨大：万块 GPU+数月的训练时间



知识迁移难度大：预训练模型蕴含丰富通识知识，而从零开始训练则等于放弃原始积累



性能差距巨大：小团队从零训练难以匹敌 GPT-3、PaLM，微调预训练模型更易取得优异效果

大模型训练层——后训练阶段流程

后训练流程包括监督微调、奖励模型训练与PPO强化学习，目的是通过融合人工偏好反馈与强化学习优化生成策略，以提升模型的对话质量、安全性和人类意图对齐度

大模型后训练阶段的流程

后训练阶段流程

步骤一：SFT监督微调

收集描述性数据，并训练一个监督学习模型

从Prompt数据库中取样

向6岁智力的模型
解释强化学习

从人类训练师
撰写期望的输出值

对行为给出奖励与
惩罚

收集的数据用以
监督学习的方式
微调大模型

收集的数据用以
监督学习的方式
微调大模型

步骤二：奖励模型训练

收集比较性数据，并训练一个奖励模型

从Prompt数据库中
取样，并得到数个
模型的回答

向6岁智力的模型
解释强化学习
模型A 模型B
回答：“...” 回答：“...”
模型 模型
回答：“...” 回答：“...”

由人类训练师对回
答进行排序

D > C > A > B

收集的数据用于训
练奖励模型

D > C > A > B

步骤三：PPO强化学习模型训练

用PPO强化学习算法对奖励模型最优化

从Prompt数据库中
另外取样

写一段关于..的故事

有监督学习初始化
PPO模型

Rk

模型给出回答

示例：“很久以前”

奖励模型对回答
打分

分数：A 分数：B
分数：C 分数：D

获得的分数通过
PPO算法优化模型

Rk


基础预训练模型虽然具备强大的语言理解和生成能力，却难以在实际对话场景中同时兼顾流畅度、准确性与安全性，对人类意图的把握也不够精细。为突破这些瓶颈，后训练阶段便应运而生——它将监督学习、奖励模型和强化学习有机结合，构建起一个从数据采集到策略迭代的闭环优化体系。

在具体操作上，后训练首先通过示例驱动的监督微调，利用严格筛选并标注的高质量对话样本校正模型的输出分布，为模型奠定符合人类偏好的初始策略；接着基于这些标注数据训练奖励模型，将主观偏好转化为可微分的评分信号，为后续评估和优化提供科学依据；最后借助近端策略优化等强化学习算法，以奖励模型的反馈为指导，不断迭代更新模型参数，实现多轮精准调优。

大模型训练层——后训练阶段流程核心技术汇总

大模型后训练阶段的核心技术有监督微调、奖励模型训练及包含PPO、TRPO、DPO、RLAIF、OREO和I-PO在内的多元化策略优化

大模型后训练阶段的核心技术汇总



- 后训练流程首先通过监督微调利用人类标注快速校正预训练模型偏差，构建符合用户期望的初始策略；随后奖励模型将偏好信息转化为可微分评分，为优化提供清晰的量化目标；最后，在策略优化阶段，多种算法协同发力——近端策略优化与信赖域优化通过约束兼顾性能与稳定，偏好对优化简化流程并降低方差，专家示范对抗式强化提升小样本学习效果，离线轨迹价值训练提高样本利用率，长链思维示例相对优化则对复杂推理进行深度对齐。
- 各环节协同发力：SFT 建立初始人类偏好策略，RM 提供明确优化目标，PPO/TRPO 防止策略崩溃，DPO 提升训练效率，RLAIF 强化小样本学习，OREO 提高数据利用率，I-PO 深化复杂推理对齐。整体上，这套流程显著提升了模型的生成质量、安全性与人类意图对齐度。

大模型训练层——后训练阶段的核心价值

大模型后训练阶段的价值是通过引入人类偏好反馈与安全约束，并结合多元化策略优化，构建闭环优化体系，显著提升模型的生成质量、安全性和复杂推理能力


大模型后训练阶段的核心价值

提升生成质量

- 通过监督微调和策略优化，模型能够输出更准确、自然且契合上下文的文本。
- 在引入监督微调与RLHF后，InstructGPT相较于 GPT-3 在遵循用户指令、保持事实准确性以及减少生成幻觉方面表现大幅优于前者

增强推理连贯性

- 基于长链思维示例与自治性技术，模型在复杂逻辑和多步推理任务中表现更稳定、一致
- Chain-of-Thought 提示技术令 PaLM 540B 在 GSM8K 数学推理基准上的准确率由标准提示下的 33% 飙升至 57%



强化安全性与对齐度

- 奖励模型与严格的优化约束有效减少有害或不当内容，使模型行为更符合人类价值观。
- RLHF 使 GPT-4 在对抗样本测试中的准确率实现翻倍增长，同时有效抑制有害或偏颇内容的输出

提高训练效率与稳健性

- 多元化优化算法（如DPO、OREO等）兼顾训练成本与稳定性，在小样本或离线数据场景下也能保持高效、可靠
- OREO 利用离线轨迹数据，在 GSM8K 和 MATH 等多步推理任务上超越包括 DPO 在内的现有方法，实现了更高的样本利用率和训练稳定性

- 后训练阶段是指在大规模预训练模型之上，依次开展监督微调、奖励模型构建与多路径策略优化等流程，旨在将人类偏好和安全标准融入模型生成机制，实现对预训练模型在生成质量、行为规范和推理能力的全方位校准。
- 后训练为大模型带来以下显著价值：首先，通过直接利用已有标注或离线数据，能够以较低成本快速提升模型性能；其次，借助奖励模型和策略约束，有效强化模型输出的安全性与对齐度，显著减少有害或偏差内容；再者，多元化的优化算法（如PPO、DPO、OREO、I-PO等）协同作用，大幅提高复杂逻辑与多步推理任务的效率和连贯性。

大模型训练层——大模型训练阶段的资源消耗

大模型训练阶段消耗的资源主要集中在预训练阶段，需要数千至上万块GPU并行运算、处理千亿级至万亿级Token数据、耗时数周至数月，占总算力消耗的90-99%

大模型训练的资源配置与时间要求



第三章节：大模型推理层

主要观点：

- 大模型推理的流程为输入文本先经分词和嵌入层映射为向量，通过多层 Transformer 的自注意力计算并结合 KV 缓存提升性能，再在词汇概率输出层生成并通过后处理拼接成完整文本
- 大模型推理后处理技术是通过温度采样、Top-k/Top-p 裁剪与贪心选择对输出概率分布进行调控，为了在生成多样性、语义连贯性与输出稳定性之间实现最佳平衡
- 大模型推理分为并行Prefill与增量Decode两阶段，分别依托模型并行与批量吞吐、以及KV缓存与注意力优化，实现了高效低延迟的推理流水线
- PD分离是将一次性上下文预填充与逐 token 串行解码解耦的策略，实现了GPU算力的精准调度与高效利用，显著降低了响应延迟并提升了整体推理吞吐率

大模型推理层——大模型推理阶段流程框架

大模型推理的流程为输入文本先经分词和嵌入层映射为向量，通过多层 Transformer 的自注意力计算并结合 KV 缓存提升性能，再在词汇概率输出层生成并通过后处理拼接成完整文本

大模型推理阶段流程框架



- ❑ 大模型推理的流程框架为：首先由分词器将用户输入切分成离散的token，再通过嵌入层将每个token映射为连续的向量表示，随后送入由多层Transformer块组成的网络，每个块内部依次完成多头自注意力与前馈网络计算以提取上下文特征。
- ❑ 在词汇概率输出层根据当前隐藏态计算下一个 token 的分布并采样生成，过程中利用 KV 缓存复用前一时刻的key与value，大幅加速自回归推理；生成的token经后处理合并成最终文本输出。
- ❑ 之所以能将模型清晰地分为训练层与推理层，是因为训练阶段需要在大规模语料上进行前向和反向传播来迭代更新全部参数，而推理阶段只需调用已优化好的前向计算流程并结合缓存机制，以最小的计算开销和内存占用实现实时、高效的文本生成。

大模型推理层——大模型推理阶段主流参数

大模型推理后处理技术是通过温度采样、Top-k/Top-p 裁剪与贪心选择对输出概率分布进行调控，为了在生成多样性、语义连贯性与输出稳定性之间实现最佳平衡

推理环节的后处理主流参数


- 温度Temperature：控制生成文本随机性的参数。较高的温度值会产生更随机的输出，而较低的温度值则会使模型更倾向于选择最可能的单词，较高的温度值，如1.0，会产生更随机的输出，而较低的温度值，如0.1，会使模型更倾向于选择最可能的单词(不可以为0)。



- Top_k：模型从最可能的“k”个选项中随机选择一个，如果k=10，模型将从最可能的10个单词中选择一个




- Top_p：模型从累计概率大于或等于“p”的最小集合中随机选择一个，如果p=0.9，选择的单词集将是概率累计到0.9的那部分。



- Greedy：在所有的下一个选项词中，选择概率最高的一个。优点是计算速度快，缺点是容易陷入局部最优解，不一定能找到全局最优解。



- 可以通过设定 Top_k、Top_p、Temperature 数值得到完全不同的输出



- 大模型推理后处理方式包括温度采样、Top-k 采样、Top-p 核采样和贪心策略。温度采样通过对 logits 进行缩放来调节生成随机性——温度越高，模型越倾向于选择低概率词以提升多样性；Top-k 采样则仅从前 k 高概率词中随机抽取，快速裁剪长尾噪声；Top-p 核采样动态选取累计概率达到 p 的最小词集，兼顾覆盖度与效率；贪心策略始终选取最大概率词，确保输出一致但可能牺牲创新性。它们协同作用，可在生成多样性、连贯性与风险控制间实现精准平衡。

- 之所以必须引入温度、k 值、p 值等超参数，而非统一采用一种采样策略，是因为不同应用场景对文本生成的多样性与稳定性需求迥异。创意写作往往需要更高的探索度，而问答或摘要则侧重准确与一致；同时，未经裁剪的原始概率分布可能包含噪声、偏见或重复模式。通过可调参数，能够灵活截断或放大概率尾部，使模型在多样性与可靠性之间获得最佳折中，满足各类下游任务的实际要求。

大模型推理层——大模型推理核心阶段

大模型推理分为并行Prefill与增量Decode两阶段，分别依托模型并行与批量吞吐、以及KV缓存与注意力优化，实现了高效低延迟的推理流水线

大模型推理核心阶段——Prefill预填充与Decode解码

- 大模型推理可以划分为 Prefill 阶段和 Decode 阶段。Prefill 阶段负责一次性处理整个输入上下文，构建并缓存各层 Transformer 的KV表示；Decode 阶段则基于这个缓存，逐步生成后续 token，每次只做增量计算。
- Prefill预填充：“阅读理解”过程，一次性处理整个问题。Decode解码：“写作”过程，一个词一个词地生成回答

特征	处理方式	计算强度	资源瓶颈	GPU利用率	比喻	工作特点	时间影响因素
Prefill阶段 (理解阶段)	并行处理所有输入Token	高，涉及矩阵-矩阵乘法	主要受限于GPU计算能力（计算密集型）	由于并行性，可以实现高利用率	读者（一次理解整篇文章）	类似“速读”，一次性理解	问题长度
Decode阶段 (生成阶段)	逐个（自回归）生成输出token	较低（每个token），涉及矩阵-向量乘法	主要受限于内存带宽和延迟（内存密集型）	由于串行性，可能存在利用率不足	作家（一次写一个词）	类似“写作”，逐步构建	回答长度

Prefill阶段的优化策略

- 特点：Prefill阶段由于能够并行处理所有输入token，主要受限于GPU的计算能力，优化重点在于最大化利用GPU的并行计算核心和高效处理批量请求。
- 核心策略：
 - 批处理技术：将多个用户的推理请求组合成一个批次进行处理，从而提高GPU的利用率和吞吐量
 - 张量并行：将模型的计算负载分布到多个GPU上。通过将模型的各层分割成更小的计算块，这些块可在不同GPU上并行执行。

Decode阶段的优化策略

- Decode阶段面临的是自回归生成的串行限制，无法像Prefill那样充分利用GPU的并行计算能力，其性能主要受限于内存带宽和延迟。
- 核心策略：
 - KV缓存：通过将先前已处理token的KV值存储在内存中，避免了重复计算。
 - 注意力机制优化：通过Flash Attention、多查询注意力等降低内存消耗并加快计算速度。


- ❑ 大模型推理阶段 Prefill 和 Decode 是两大核心阶段，Prefill 阶段负责一次性并行处理所有输入token，通过多层Transformer计算并构建 KV 缓存，以“速读”形式完整理解上下文；Decode 阶段则采用自回归方式逐token生成输出，每次仅做增量推理并依托前序缓存，类似“逐字成文”地写出答案。
- ❑ 根据两阶段的资源与计算特性，需分别制定优化策略：对Prefill阶段，应强化GPU计算吞吐——通过批量合并多个请求提升并行度，并运用模型并行将Transformer层切分至多块GPU；对Decode阶段，则侧重内存与延迟优化——利用KV缓存避免重复计算，并引入Flash Attention、多查询注意力等技术以降低内存带宽占用和加速串行推理。

大模型推理层——大模型推理PD分离技术

PD分离是将一次性上下文预填充与逐 token 串行解码解耦的策略，实现了GPU算力的精准调度与高效利用，显著降低了响应延迟并提升了整体推理吞吐量

大模型推理核心技术——Prefill与Decode分离


PD两阶段时间占比图



PD两阶段每秒吞吐量占比图



■ 由实验可见，Prefill与Decode阶段存在高达137×的速度差距，其中Decode流程耗时占总推理时间99%以上，表明单一的流水线不能充分发挥GPU并行算力；因此，将推理流程中的Prefill与Decode分离，并针对Decode阶段实施专门的缓存复用与内存带宽优化，才是释放硬件潜能、显著提升推理效率的关键。



推理性能实现显著提升

PD分离直接降低了用户感知的首次响应时间（TTFT）和后续生成时间（TPOT），使得交互体验更快、更流畅。

硬件资源利用率提升

PD分离的差异化管理则能确保昂贵的GPU等硬件资源在Prefill和Decode这两个特性迥异的阶段都得到更充分、更有效的利用。

独立优化路径得以实现

PD分离允许开发者为计算密集的Prefill和内存带宽密集的Decode这两个阶段，各自独立地应用最前沿、最有效的优化技术。

为先进的系统调度奠定基础

实施连续批量处理等现代高效调度算法，其前提就是系统能够区分P和D状态。PD分离使得调度器能够智能地、动态地管理和组合请求。

- ❑ 传统推理流程将Prefill阶段与Decode阶段一体化处理，导致Decode无法发挥GPU的并行计算能力，其耗时占总推理时间超过99%，既造成响应延迟极高，也让海量算力资源在生成过程中严重浪费。
- ❑ 而PD分离策略将Prefill与Decode解耦后，能够为两阶段分别应用最优调度：Prefill可批量合并请求、最大化GPU并行吞吐，显著缩短首次响应时间（TTFT）；Decode则依托KV缓存、内存带宽优化及专用流水线，大幅提升后续生成速率（TPOT）。这一分离不仅显著提升整体推理性能和资源利用率，还为独立的分阶段优化与系统级智能调度奠定了坚实基础。

第四章节：大模型产业基础大模型市场洞察

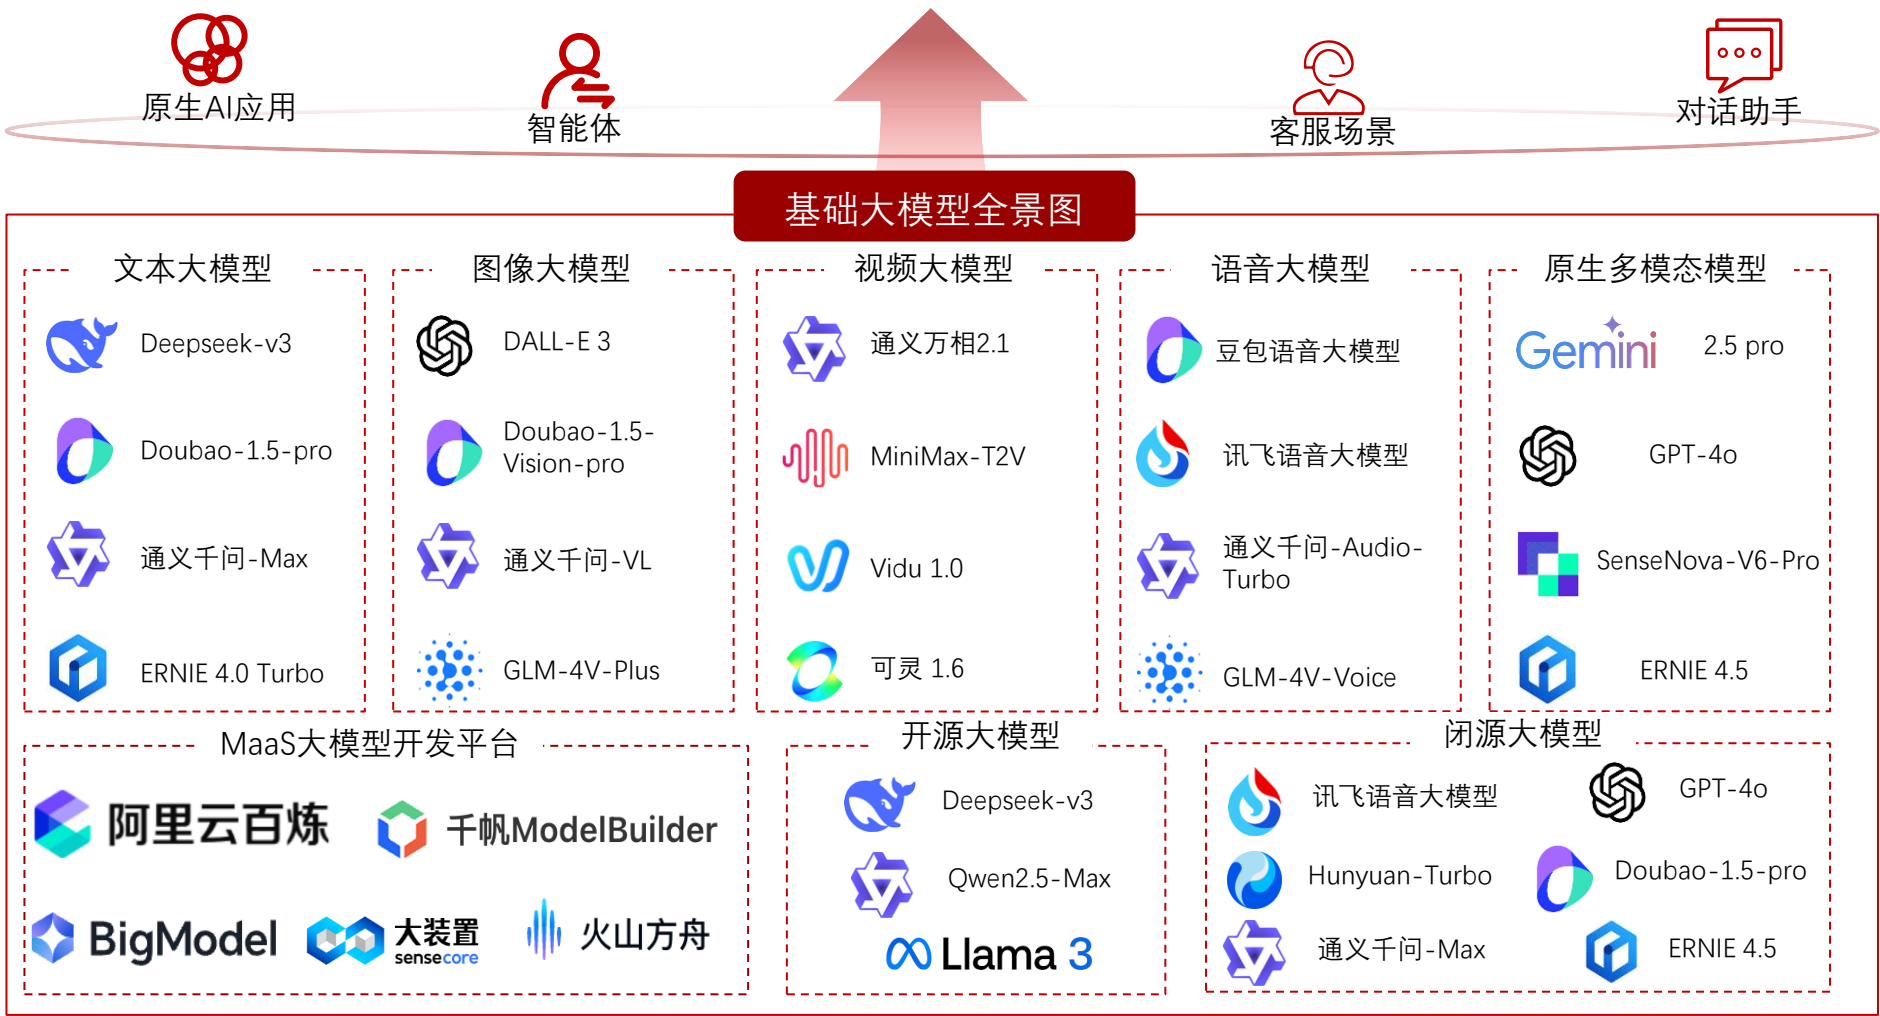
主要观点：

- 大模型基础模型层是基础预训练模型与开发平台的有机集合，价值在于通过统一的算力接口与灵活的微调工具，为上层应用提供低成本、高效率的算法支撑，加速场景落地
- 大模型基础模型层是基础预训练模型与开发平台的有机集合，价值在于通过统一的算力接口与灵活的微调工具，为上层应用提供低成本、高效率的算法支撑，加速场景落地
- 中国大模型产业已进入全球竞争的第一梯队，其核心优势源于国内市场已形成的差异化布局：各厂商正依托自身禀赋，在对标国际顶尖性能的同时，以成本效益等非对称优势开辟新的竞争维度
- 大模型厂商正告别技术参数与价格同质化内卷，全面转向一个依托各自核心禀赋、展开差异化战略竞争的新阶段
- 大模型市场的关注焦点正发生迁移，已从对模型极限性能的单一追求，全面转向以业务场景契合度与商业价值为核心的综合评估

基础大模型市场洞察——基础大模型全景图谱

全球大模型产业呈现出“技术终局趋同，商业路径分化”的核心格局：所有厂商均以原生多模态为统一演进目标，但在实现路径上则分裂为闭源平台与开源生态两大阵营

基础大模型层全景图谱



- 无论是中国还是海外的头部厂商，其技术演进路线均明确指向原生多模态，即从处理单一信息类型向融合处理文本、视觉、听觉的统一智能体演进，以GPT-4o和Gemini为代表的模型已成为业界共同追逐的技术标杆。
- 市场正沿着两条不同的商业化道路分野，一是以闭源模型和MaaS平台为核心的“平台生态化”路径，旨在构建高价值、高粘性的商业闭环；二是以Llama、Qwen、Deepseek为代表的“开源普惠化”路径，旨在通过开放技术、构建广泛的开发者社区来赢得市场，这两种路径的博弈与共存定义了当前的市场竞争格局。

基础大模型市场洞察——基座大模型调用量规模


随着大模型进入指数级增长的产业应用期，市场调用量正迅速向具备云基础设施与海量应用场景双重优势的头部厂商归拢

中国基础大模型调用量规模，2024.01-2025.12E

单位：万亿Tokens

➤ 调用量口径：Tokens计算在公有云上调用大模型的Token总量，不包括APP产生的调用量、出海的调用量、以及在MaaS平台定制化微调模型的调用量。

中国大模型公有云调用量2024.01-2025.12E



从2024年至今，大模型的调用量的指数级增长，公有云大模型调用量正经历爆发式的指数增长，从2024年1月份的8,000亿Tokens增长至2025年4月份的71.8万亿标志着市场已从前期的技术验证与小范围试点，全面迈向大规模产业应用的新阶段。

其次，市场竞争格局已清晰呈现为“一超两强”的寡头形态：火山引擎凭借其庞大应用生态的驱动，占据了近半壁江山，市场领导地位显著；阿里云与百度智能云则构成稳固的第二梯队，共同分割了近四成市场。这种高度集中的调用量表明，强大的云基础设施与海量的自有应用场景，已成为大模型商业化落地的关键竞争壁垒。

基础大模型市场洞察——基础大模型厂商竞争差异化路线初显

大模型厂商正告别技术参数与价格的同质化内卷，全面转向一个依托各自核心禀赋、展开差异化战略竞争的新阶段

基础大模型厂商竞争差异化路线初显



战略核心是“云智一体”，强调全栈自研与产业深度融合。依托从昆仑芯、飞桨深度学习框架到文心大模型的全栈技术，百度主打端到端的解决方案。其路径是通过“B端标杆案例”辐射千行百业，实现模型技术与产业价值的紧密挂钩。



以行业大模型巩固根据地市场，基于在教育、医疗、司法、政务等领域的长期数据和渠道积累，讯飞星火大模型的核心是赋能并深化其已有的B端和G端业务。通过“软硬一体化”的产品，将AI能力直接转化为C端用户价值。



采用“内部孵化、外部服务”的战略，以极致的应用场景反哺技术。其豆包大模型首先服务于抖音、今日头条、飞书等内部海量用户产品，在真实、高并发的应用实践中快速迭代和优化。然后，通过火山引擎将这些经过大规模验证的AI技术与解决方案开放给B端客户。



定位为“AI基础设施的提供者”，力推“模型即服务(MaaS)”与开源生态。阿里云以通义大模型为核心，通过其公有云平台，向开发者和企业提供标准化的模型服务，旨在通过生态的力量赋能产业，非直接主导所有行业的定制化开发。



采取“生态嵌入式”的务实路径，以场景驱动模型发展。腾讯将混元大模型的能力无缝融入其庞大的社交（微信/QQ）、内容（视频/新闻）、游戏及企业服务（腾讯会议/企业微信）生态中，利用海量、高价值的自有场景带动大模型应用发展。



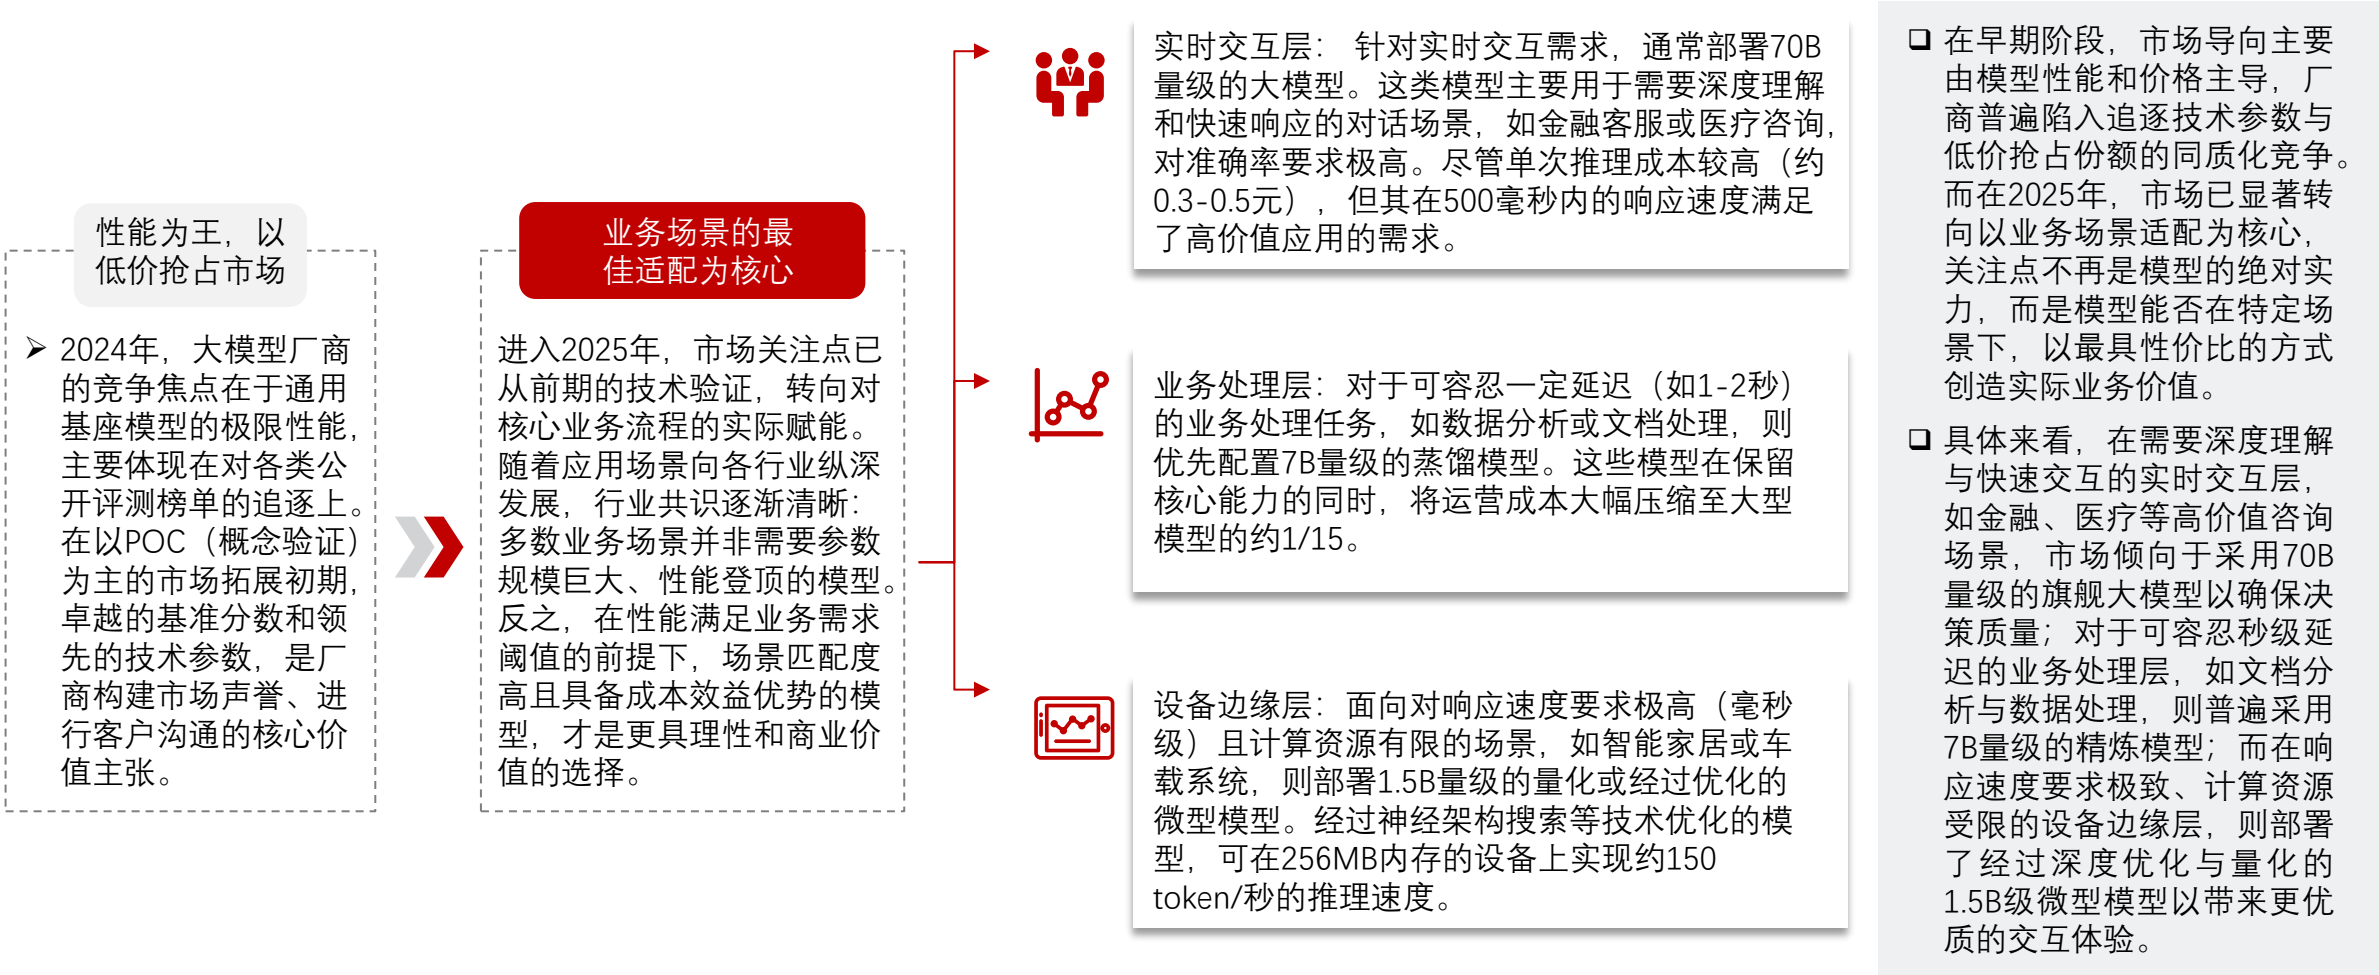
执行“非对称竞争”策略，以极致技术创新和成本效率为破局点。依托幻方量化的算力支持，Deepseek专注于模型架构的底层创新。其核心路径是通过开源顶尖模型构建全球技术影响力，吸引人才，并非急于进行直接的商业变现。

随着时间推移，大模型厂商从初期卷模型参数、卷价格的同质化竞争，正逐步演变为依托自身核心禀赋，寻求差异化发展的清晰格局。例如，百度智能云坚持“云智一体”的全栈路线，致力于产业深度融合；阿里云专注“模型即服务(MaaS)”的AI基建与开源生态；腾讯云选择“场景驱动、生态嵌入”的务实路径；科大讯飞则深耕“行业垂直整合”的根据地模式；火山引擎以“应用反哺技术”双轮驱动；而Deepseek则凭借“极致性价比”的非对称创新，在全球技术社区另辟蹊径。

基础大模型市场洞察——大模型正从追逐顶尖性能向不同场景适配转移

大模型市场的关注焦点正发生迁移，已从对模型极限性能的单一追求，全面转向以业务场景契合度与商业价值为核心的综合评估

大模型的市场导向从性能为王向业务适配转变



第五章节：大模型基础设施层产业全景洞察

主要观点：

- 智算中心的底层基础设施体系高度复杂，涵盖供配电、制冷、机柜、布线、防雷、防火等多系统协同，核心在于保障算力设备的高可用性与稳定运行
- 2020年至2027年，中国算力建设呈现高速增长态势，整体算力结构正由以通用计算为主向智能计算为主转型，同时，AI服务器出货量持续上升、推理负载占比逐年提升
- 数据中心制冷技术正由传统风冷向液冷跃迁，液冷以系统级能效最优和高热密支撑能力，成为满足下一代智算中心PUE控制红线的核心路径
- 全球与中国数据中心PUE已进入结构瓶颈期，传统节能路径失效，未来能效跃迁需依赖冷却系统革新与能源架构重构

大模型基础设施层——智算中心基础构成

智算中心的底层基础设施体系高度复杂，涵盖供配电、制冷、机柜、布线、防雷、防火等多系统协同，核心在于保障算力设备的高可用性与稳定运行

智算中心基础构成



大模型基础设施层——GPU芯片功耗增加

新一代GPU芯片以精度可调、互联增强与极限功耗为特征，在大幅释放AI算力的同时，对智算基础设施提出结构性重构要求

新一代GPU芯片功耗显著增加

架构	A100	H100	H200	GH200	B100	B200	Full B200	GB200
	Ampere	Hopper	Hopper	Hopper	Blackwell	Blackwell	Blackwell	Blackwell
显存大小	80GB	80GB	141GB	141/144GB	180/192GB	180/192GB	192GB	384GB
显存带宽	2TB/s	3.35TB/s	4.8TB/s	4.9TB/s	8TB/s	8TB/s	8TB/s	16TB/s
FP16算力 (FLOPS)	312T	1P	1P	1P	1.75P	2.25P	2.5P	5P
INT8算力 (OPS)	624T	2P	2P	2P	3.5P	4.5P	5P	10P
FP8算力 (FLOPS)	-	2P	2P	2P	3.5P	4.5P	5P	10P
FP6算力 (FLOPS)	-	-	-	-	3.5P	4.5P	5P	10P
FP4算力 (FLOPS)	-	-	-	-	7P	9P	10P	20P
NVLink带宽	600GB/s	900GB/s	900GB/s	900GB/s	1.8TB/s	1.8TB/s	1.8TB/s	3.6TB/s
功耗	400W	700W	700W	700W	1,000W	1,200W	1200W	2,700W

- ❑ NVIDIA 新一代 GPU 芯片从 Ampere（A100）到 Hopper（H100/H200/GH200）再到 Blackwell（B100/B200/GB200）架构的跨代演进路径，突显出其在AI时代对大模型训练与推理需求的系统性回应。
- ❑ 核心算力指标如FP16、INT8、FP8等在Blackwell架构下呈现倍数级增长，尤其在FP4/FP6低精度计算能力上显著提升，反映出面向AI大模型推理与训练的新架构已全面向极致性能和高能效比优化。此外，显存带宽从A100的2TB/s提升至GB200的16TB/s，NVLink也翻倍扩展至3.6TB/s，旨在支撑大模型分布式并行训练需求。而功耗亦同步激增至2700W，表明下一代GPU将显著推高智算中心在电力、散热和系统设计方面的基础设施门槛，对系统集成商提出更高挑战，也加速数据中心向液冷与高密度部署形态演进。

大模型基础设施层——新服务器功耗增加

AI服务器正向“高精度异构算力+极限带宽互联+超线性能耗密度”演进， 重构数据中心的供电、 散热与系统架构边界

新服务器功耗持续增加

架构	HGX A100	HGX H100	HGX H200	HGX B100	HGX B200
	8 × A100 SXM	8 × H100 SXM	8 × H200 SXM	8 × B100 SXM	8 × B200 SXM
显存大小	640GB	1.1TB	1.1TB	1.44/1.5TB	1.44/1.5TB
显存宽带	8 × 2TB/s	8 × 3.35TB/s	8 × 4.8TB/s	8 × 8TB/s	8 × 8TB/s
FP16算力	2.4P	8P	8P	14P	18P
INT8算力	4.8P	16P	16P	28P	36P
FP8算力	-	16P	16P	28P	36P
FP6算力	-	-	-	28P	36P
FP4算力	-	-	-	56P	72P
GPU-to-GPU宽带	600GB/s	900GB/s	900GB/s	1.8TB/s	1.8TB/s
NVLink宽带	4.8TB/s	7.2TB/s	7.2TB/s	14.4TB/s	14.4TB/s
以太网网络	200Gb/s	400Gb/s+200Gb/s	400Gb/s+200Gb/s	2×400Gb/s	2×400Gb/s
IB网络	8×200Gb/s	8×400Gb/s	8×400Gb/s	8×400Gb/s	8×400Gb/s
GPU功耗	3.2kW	5.6kW	5.6kW	5.6kW	8kW
总功耗	6.5kW	10.2kW	10.2kW	10.2kW	14.3kW

- ❑ 随着HGX服务器从A100迭代至B100/B200， 算力系统已不再仅追求单精度性能提升， 而是呈现出以精度可变、 带宽扩展和功耗堆叠为核心特征的结构性价跃趋势。
- ❑ 具体表现为： FP8/FP6/FP4等低精度算力指数级上升， 标志AI推理需求正主导算力体系设计重心； NVLink互联和GPU-to-GPU通信能力翻倍增长， 有效缓解大模型并行训练中的通信瓶颈； 而单节点总功耗从6.5kW跃升至14.3kW， 意味着智算服务器已成为数据中心能耗与散热规划的核心负载单元， 传统散热、 电力系统将面临系统性重构压力。
- ❑ 整体而言， AI基础设施正从“资源堆叠”走向“能效协同”， HGX架构的升级已不再是GPU性能提升的简单累加， 而是数据中心级技术协同的高度集成体现。

大模型基础设施层——成本影响因素分析

智算中心造价由客户需求、技术方案、冗余设计、规模、区位与设备选型等多因素共同决定，呈现高度定制化与系统性成本差异

智算中心成本影响因素分析

客户群体

不同客户群体对建设智算中心工艺部分造价有着显著的差异。
例如：金融行业客户重视安全性，对智算中心电气、暖通系统的安全性要求比较高，建设成本比较高；互联网客户比较注重能效指标，注重经济性，建设成本相对较低。

技术方案架构

制冷系统：液冷模式、风冷模式、冷冻水系统自然冷却技术、氟泵、间接蒸发冷等形式。
供电架构：单路UPS+市电、双路UPS、HVDC高压直流+市电、市电直供等多种模式
不同的方案架构也是影响智算中心的机电造价的因素之一。

设计冗余与标准化

不同的可靠性级别对智算中心的造价有着显著的影响，根据国标要求，数据中心分别三个级别，按照C级别标准，供电采用单独N路建设成本比较低，如果采用B级标准，N+1冗余配置，成本预计增加10%-20%，如果采用A级标准，2N容错配置，成本预计增加30%-50%。

规模效应

设备采购的折扣一个智算中心的成本很大程度取决于项目设备采购的价格，智算中心的体量越大，对于设备采购的价格审批折扣相对越低；
施工效率的提升基于智算中心的快速交付和快速相应能力，智算中心采用模块化预制方式，可以大大缩短施工工期，减低人工成本15%-20%。

地域条件

气候条件影响制冷成本，在北方地区，利用先天气候条件，全年50%以上的时间都可以停止冷机或压缩机的运行，大大减低了制冷设备的投资。
土地与基建成本，一线城市土地的成本比价高，间接的推高了智算中心的成本，环保限制导致一些一线城市被迫采用储能系统作为后备电源，增加了初期造价。

设备国产化率

智算中心工艺部分（机电基础设施）造价中，设备价格占比是比较大的，占比最大的两个系统电气系统和暖通系统。
除了部分设备沿用合资品牌外，很多设备品牌已经有合资品牌向国产品牌转换的趋势，可以有效的降低成本。

大模型基础设施层——智算中心的成本与能耗

高密度智算中心的成本与能耗矛盾正在逼迫系统从“设备堆叠”向“冷算协同”的架构性变革过渡，制冷效率已成为TCO与PUE优化的核心突破口

智算中心的成本与能耗

➤ 数据中心能耗结构

□ 以一个英伟达H100构成的千卡集群智算中心为例，



- 报告完整版/高清图表或更多报告：请登录 www.leadleo.com
 - 如需进行品牌植入、数据商用、报告调研等商务需求，欢迎与我们联系
- 联系邮箱：service@leadleo.com


➤ 平台软件和液冷改造成本约1千万；

共计约3.5亿元的总成本。

□ 而智算中心

左右。

IT设备
能耗
系统
其他



能耗结构高度集中于IT设备与制冷系统，前者占67%，反映出计算与存储负载仍是能耗核心驱动；而制冷占27%，成为除IT主设备外的最大能耗来源，凸显其关键地位。供电系统与照明/其他设施仅占总能耗的6%，显示其优化空间有限。当前制冷链路正成为能效结构升级的首要抓手，技术演进方向需围绕“冷却-算力-负载”三者的深度联动，向液冷分布式、电源耦合式、节点级温控等新架构演进，重塑TCO控制逻辑与能源治理体系。

□ 智算中心成本结构正呈现出“重资本、强能耗、轻配套”的非均衡态势，其中以H100为代表的GPU集群构成初始投入核心，占比超过85%，形成高算力密度驱动下的设备集约型模型；但该结构亦带来显著后期能效负担，运行支出中电力消耗、冷却成本与高可靠运维投入成为OPEX主导项，年支出逼近初始成本的15%。在此背景下，能源成本的构成深度映射出热功耗路径瓶颈——IT设备与制冷系统合计占据能耗94%，其中制冷消耗高达27%，已成为PUE优化的临界短板。供电与照明系统边际能耗占比极低，显示其优化空间有限，当前制冷链路正成为能效结构升级的首要抓手，技术演进方向需围绕“冷却-算力-负载”三者的深度联动，向液冷分布式、电源耦合式、节点级温控等新架构演进，重塑TCO控制逻辑与能源治理体系。

大模型基础设施层——商业模式

智算中心商业模式正从传统基础设施托管向算力、平台、模型与应用全链条服务演进，服务形态高度多元化以匹配不同类型客户需求

智算中心商业模式


类型	商业模式	介绍	供应方	需求方
IaaS 基础设施即服务	机房托管服务	在传统数据中心机房托管基础上，提供更高功耗、配电和网络定制	智算转型的数据中心服务商、中立的智算中心服务商等	头部云商及 AI 公司、大型央国企等
	算力租赁服务	以云服务形式租赁智能算力，按使用时间和规模收费	云厂转型的智算服务商、中立的智算中心服务商等	中小型科技公司、IT 公司、非连续需求的科研机构等
PaaS 平台即服务	AI 平台服务	提供人工智能应用开发工具和平台	头部 IT 公司	中小企业和开发者
MaaS 模型即服务	模型定制服务	模型定制、精调、部署等 AI 大模型全流程服务	成熟的大模型供应商（具有 AI 大模型技术能力）	中小垂直行业企业
SaaS 软件即服务	AI 应用服务	直接应用于企业业务，提供人工智能分析、决策等服务	具有 AI 能力的垂直行业头部企业	小型垂直行业企业

- ❑ 底层IaaS层通过机房托管与算力租赁形成规模化资源池，解决基础设施弹性供给问题，是支撑智算经济的“土地”；
- ❑ 中层PaaS与MaaS通过抽象AI工具与模型服务形成通用化能力中台，推动智力生产要素的标准化与模块化，是加速算法落地与技术扩散的“流水线”；
- ❑ 顶层SaaS则完成面向垂直场景的最后一公里转化，直接连接行业用户价值，构建高粘性的AI服务生态。
- ❑ 整体上，智算中心商业模式正由资源密集型向能力密集型跃迁，供给侧由重资产IDC运营商延伸至轻资产模型与平台提供方，需求侧则从头部企业向中小企业乃至行业用户全覆盖，体现出智算能力“即服务”化、模块化、生态化的典型产业升级趋势。

大模型基础设施层——制冷技术PUE发展趋势

数据中心制冷技术正由传统风冷向液冷跃迁，液冷以系统级能效最优和高热密支撑能力，成为满足下一代智算中心PUE控制红线的核心路径

制冷技术PUE发展趋势




当前数据中心制冷技术正围绕“单位算力能效最优”目标发生范式转移，液冷技术因其在热交换路径最短、传热效率最高、系统集成度最强等方面具备物理极限优势，已在PUE<1.10的高性能场景中形成实际部署优势，尤其是相变与非相变浸没式方案，具备支撑>30kW/机柜热密度的能力，代表下一代高密度智算中心的主流制冷趋势。相比之下，自然冷技术虽在特定气候带具备阶段性降PUE价值，但在高负载稳定性、年均适应性和空间利用率方面存在显著瓶颈；而冷冻水与风冷系统PUE普遍在1.30以上，已难以满足未来中国“双碳”战略和智算基础设施能效红线约束。制冷技术正从风冷—冷冻水—自然冷—液冷呈加速跃迁态势，本质驱动是热功耗密度攀升与绿色算力刚性目标之间的深层博弈。

大模型基础设施层——供电系统

数据中心供电体系正由静态供电网络向智能化、高冗余、高响应性的多级能质协同架构升级，UPS在其中承担电能治理与系统耦合的核心职能

中国数据中心主要供配电设备拆解



- 当前数据中心供电系统正在向“高可用+高并发+高密度”架构演进，核心在于构建以UPS为枢纽的多级供电链路，实现电源路径N+1、2N甚至2(N+1)的冗余配置，以适应AI训练等重载场景对电能连续性和电压品质的极致要求。
- 系统链路从市电/发电机—中压柜—变压器—低压配电—UPS输入/输出—精密配电—IT负载形成闭环，强调端到端电能质量控制、快速切换能力与精细化配电能力。UPS从传统“供电保障”角色转向“电能治理+负载适配+系统耦合”核心节点，其输出能力与响应时间成为衡量供电系统技术等级的关键指标。
- 此外，系统正普遍叠加数字化运维能力，通过链路状态感知、电能质量分析及AI预测性告警，提升整体彩控能力。


大模型基础设施层——中国投运/在建/规划智算中心项目区域分布

智算中心布局正在由资源承载与需求牵引双轮驱动，呈现东部聚集化与中西部资源导向型的功能性分工格局

中国投运/在建/规划智算中心项目区域分布（截至2024年8月）

中国投运/在建/规划智算中心项目区域分布

单位：个




- 中国智算中心项目布局呈现出“东部集聚、西部分散”的区域发展格局，其中江苏、广东、山东等东部经济强省合计占比超过20%，依托于算力需求密集、网络基础完备、电力保障能力强等优势，成为智算基础设施建设的核心承载区。
- 与此同时，中西部地区如内蒙古、四川、贵州等亦加速布局，以低电价、土地资源充裕和政策引导为支撑，构建“东数西算”典型落地场景。
- 整体来看，区域分布体现出算力基础设施建设正在由资源导向走向“需求-资源-政策”多因素耦合驱动，头部省份进入以应用牵引为核心的集约化发展阶段，非头部地区则更多承担基础设施外溢与低成本承接角色，形成分工明确的“主干—边缘”协同生态。

大模型基础设施层——智算中心参与者分布


智算项目由地方政府主导发起，算力资源则加速向头部互联网与云厂商集中，形成“政策引导+市场集中”的双层格局

智算中心参与者分布

- 地方政府
- 基础电信运营商
- 互联网及云厂商
- 其他



中国智算中心项目主体分布（按项目数量）




中国智算中心项目主体分布（按算力规模）

- 当前智算中心呈现“项目发起多元化、算力资源集中化”双重特征：从项目数量维度看，地方政府主导项目占比最高，达到33.9%，展现出政策驱动在智算基础设施布局中的先发作用；
- 但从算力规模维度看，互联网及云厂商占比高达35.0%，成为核心算力资源的掌控者，反映出资本、技术和模型能力对资源整合的强驱动效应。基础电信运营商在两项指标中占比相对稳定，扮演网络支撑与中性服务商角色；而“其他”类参与者占比超过四分之一，代表产业生态正由头部主导向联盟式与联合体模式演化。结构差异表明：智算项目呈现“政策起盘—市场放量”的运行逻辑，未来算力资源将加速向具备大模型部署能力与产业对接能力的主体集中。

大模型基础设施层——数据中心电力需求

算力规模化推动数据中心用电量跃升为区域能源主负荷，中国正成为全球电力-算力结构重构的关键压力测试场

数据中心电力需求




□ 全球智算中心正步入“电力支撑瓶颈期”，核心IT负载电力需求2023-2028年CAGR将超20%，其中中国以2026年285TWh的预测用电量超越欧美，成为全球电力消耗增长主引擎。这一趋势反映出高热密AI训练集群部署对电力系统构成系统性压力，不仅挑战现有PUE优化极限，更使传统以“负载就地部署”为主的能源结构面临解构。区域对比来看，中国算力用电增长主要由政策主导的大规模集群化建设与地方政府资源调配推动，其电力消耗强度已超过多数国家工业品类，正在从边缘用能体转化为电力基础设施主导负荷中心。在碳约束、调度弹性、电价机制等多维约束趋紧背景下，算力电力协同规划将成为未来基础设施布局和资源要素配置的核心命题，亟需推动从“电随算走”向“算随电走”的能算匹配机制转型。

大模型基础设施层——全球及中国数据中心平均年PUE

全球与中国数据中心PUE已进入结构瓶颈期，传统节能路径失效，未来能效跃迁需依赖冷却系统革新与能源架构重构

全球及中国数据中心平均年PUE



- 当前全球及中国数据中心PUE正处于“边际优化停滞—架构性重构”过渡阶段，全球平均PUE自2018年起长期滞留在1.6，反映出传统基于风冷、局部配电优化等路径的节能潜力已基本耗尽，进入系统性瓶颈期。
- 中国地区PUE虽在1.4–1.5之间，略优于国际平均水平，但各区域间差异趋于收敛，表明除极端气候或极端电价外，传统地理禀赋因素对能效的决定性影响正在削弱。
- 未来能效提升需依赖底层系统架构升级，如液冷系统普及、算热协同调度与电源路径简化等。
- 此外，中国PUE领先的核心驱动来自政策压制红线而非技术自主突破，若缺乏底层架构创新支撑，行业将面临算力扩张与能耗红线的结构性冲突风险。

□ PUE是指能源使用效率，是数据中心消耗的所有能源与IT负载使用的能源之比

第六章节：AIDC全球版图深度研究


主要观点：

- 全球算力建设正从“总量扩张”转向“结构跃迁”，智算能力成为衡量技术竞争力的关键指标。2023年全球智算力规模达875EFLOPS，首次超过基础算力，较2020年增长近百倍
- 2020年至2027年，中国算力建设呈现高速增长态势，整体算力结构正由以通用计算为主向智能计算为主转型，同时，AI服务器出货量持续上升、推理负载占比逐年提升
- 中国算力基础设施正处于从“数量型扩张”向“质量型升级”的关键转型期。在机架总量稳步增长的同时，能耗激增暴露出传统建设模式难以支撑新一代高密度计算负载的现实问题
- 算力资源正在由通用计算向智能计算转移，互联网与服务业成为智能算力应用的主要推动力量，而其他行业的智能化转型正处于加速阶段，未来存在较大成长潜力

AIDC全球版图深度研究——全球算力及智算建设规模

全球算力建设正从“总量扩张”转向“结构跃迁”，智算能力成为衡量技术竞争力的关键指标。2023年全球智算力规模达875EFLOPS，首次超过基础算力，较2020年增长近百倍

全球算力及智算建设规模



- 2020至2023年，全球算力规模持续快速增长，截止2023年底，全球计算设备侧算力总规模达1,397EFLOPS。
- 智算规模从2020年的仅107增长至2023年的875EFLOPS，首次超过基础算力，成为主导性增长引擎。这一趋势背后，是以大模型、深度学习为代表的人工智能技术加速发展，对GPU等高性能算力资源形成爆发式需求。
- 结构性变化也带来区域格局重构。美国在全球算力中占比由2022年的34%提升至2023年的41%，继续稳居主导地位。而中国虽然整体占比略降至31%，但智算力建设进展显著，从2022年的27%提升至2023年的39%，反映出其在资源受限背景下优先配置AI相关算力的战略选择。相比之下，欧洲、日本及其他区域算力份额整体下滑，全球算力资源呈现加速集中态势。

来源：专家访谈，头豹研究院

AIDC全球版图深度研究——中国算力建设现状（1/3）

2020年至2027年，中国算力建设呈现高速增长态势，整体算力结构正由以通用计算为主向智能计算为主转型，同时，AI服务器出货量持续上升、推理负载占比逐年提升

中国算力及智算建设规模




- 2020年至2027年，中国智能算力呈现爆发式增长，预计将从75 EFLOPS跃升至1,117 EFLOPS，年均复合增速超60%，成为推动整体算力扩张的核心力量；相较之下，通用算力（基于FP64）增长相对缓慢，2027年预计仅达117 EFLOPS。智能算力增速自2023年起反超通用算力，反映出AI驱动的计算需求持续上升。
- AI服务器出货量从2020年的15万台增长至2024年预计的42万台，年均增长超29%。同时，AI服务器的推理类任务占比逐年上升，至2027年将占据主导地位，表明大模型训练趋于平台化、集中化，推理应用正加速落地，算力部署由“重训练”向“强推理”转型。
- 综合来看，中国正加快构建以智能算力为核心的新一代算力基础设施。

AIDC全球版图深度研究——中国算力建设现状（2/3）

中国算力基础设施正处于从“数量型扩张”向“质量型升级”的关键转型期。在机架总量稳步增长的同时，能耗激增暴露出传统建设模式难以支撑新一代高密度计算负载的现实问题

中国数据中心及功率密度



- ❑ 中国数据中心机架规模自2020年起持续扩大，从400万架增长至2024年的880万架，年均复合增长率约为22.3%，其中2023至2024年增幅为8.6%，显示增长趋于平稳。
- ❑ 同时，算力中心耗电量增长更为显著，从2020年的939亿千瓦时上升至2023年的2700亿千瓦时，仅2022至2023年一年间增长幅度就高达107.7%，反映出高算力需求带动能耗急剧上升，2030年预计将达到4000亿千瓦时。
- ❑ 数据中心规模与电耗增长虽均呈正相关趋势，但后者增长速度远超前者，说明单架机功耗和算力密度正在提升。

- ❑ 算力密度的提升背后，体现的是AI训练、智能推理和海量数据处理任务的集中爆发，对硬件架构、能源调度、运维效率提出更高要求。意味着未来算力中心的建设不能再简单依靠堆砌服务器，而必须从根本上优化能效结构，强化绿色低碳技术的应用，如采用高效能GPU/AI芯片、推进液冷等先进散热技术、通过AI实现能耗智能调控，并布局靠近可再生能源资源的“算力能源一体化”区域。
- ❑ 2030年电耗将达到4,000亿千瓦时这一预测数字，警示决策层必须前瞻性地制定资源优化与碳排放控制策略，以保障算力发展与“双碳目标”的协调统一。
- ❑ 未来中国算力发展的重点将从“建得快”转向“建得强、用得省”，科技底座与绿色低碳的融合将成为决定全球算力竞争力的核心因素。

AIDC全球版图深度研究——中国算力建设现状（3/3）

中国正系统推进国家算力枢纽布局，通过“东数西算”战略在宁夏、内蒙古、贵州等重点区域部署超大规模数据中心集群，预计至2025年建成逾1.3万MW算力容量

中国算力资源分布情况

□ 宁夏枢纽算力网络国家枢纽节点

中卫算力中心集群

2025年计划建成算力中心容量达1,650MW。

□ 甘肃枢纽算力网络国家枢纽节点

庆阳算力中心集群

2025年计划建成算力中心容量达750MW。

□ 成渝枢纽算力网络国家枢纽节点

天府算力中心集群

四川2025年计划建成算力中心容量达750MW。

重庆算力中心集群

2025年计划建成算力中心总容量达1,250MW。

□ 贵州枢纽算力网络国家枢纽节点

贵安算力中心集群

2025年计划建成算力中心总容量达2,000MW。

□ 内蒙古自治区算力网络国家枢纽节点

和林格尔算力中心集群

2025年计划建成算力中心容量达2,500MW

□ 京津冀枢纽算力网络国家枢纽节点

张家口算力中心集群

2025年计划建成算力中心容量达1,750MW。

□ 长三角枢纽算力网络国家枢纽节点

长三角生态绿色一体化发展示范区集群

2025年计划建成算力中心容量达250MW。

芜湖算力中心集群

2025年计划建成算力中心总容量达1,600MW。

□ 粤港澳大湾区枢纽算力网络国家枢纽节点

韶关算力中心集群

2025年计划建成算力中心总容量达1,250MW。




AIDC全球版图深度研究——行业算力需求


算力资源正在由通用计算向智能计算转移，互联网与服务业成为智能算力应用的主要推动力量，而其他行业的智能化转型正处于加速阶段，未来存在较大成长潜力

中国智能算力及智能算力分布及建设需求，按行业划分

算力行业分布，2023年



智能算力行业分布，2023年




- 2023年，中国智能算力及整体算力的行业分布展现出显著的结构性差异，反映出各行业在数字化与智能化转型过程中的算力依赖程度与发展重点。互联网行业无疑是最主要的算力驱动者，在整体算力中占比达39.0%，在智能算力中更是高达53.2%，充分体现其在大模型、推荐算法、内容生成等方面对高性能智能算力的强烈需求。
- 服务行业在智能算力中的占比显著提升，达到17.8%，相比其在整体算力中的7.9%，表明该行业在客服自动化、智能分析与个性化服务等场景下的AI应用加速落地。相较之下，政府、电信、制造、教育和金融等行业在两类算力中所占比例相对稳定，但其在智能算力中的占比普遍低于整体算力，显示出这些传统行业在智能化升级方面仍有较大的提升空间。

AIDC全球版图深度研究——美国算力建设现状（1/2）

美国算力资源分布呈现“多中心、强集聚”的特征，其中北弗吉尼亚州以5,350MW的规模稳居全球最大数据中心市场，占美国整体数据中心资源的控制率为0.26%

美国算力资源建设现状

数据中心规模（个数） ● 0-30个 ● 30-100个 ● 100-300个



主要市场	规模（MW）	控制率
亚特兰大，乔治亚州	2,010	0.63%
芝加哥，伊利诺伊州	1,100	1.03%
达拉斯，德克萨斯州	1,600	1.77%
凤凰城，亚利桑那州	2,050	1.29%
北方加利福尼亚	810	3.41%
北方弗吉尼亚	5,350	0.26%

- ❑ 北弗吉尼亚作为“全球算力心脏”，显示出领先者优势持续强化的趋势；而以凤凰城、亚特兰大为代表的新兴区域则依托基础设施和地理优势快速崛起，正在重塑全美算力布局格局。
- ❑ 北弗吉尼亚州以5,350MW的总规模稳居第一，是全球最大的单一数据中心集群，其规模远超其他区域，虽然控制率仅为0.26%，但因其拥有极为密集IDC资源和优质的网络接入条件，长期作为美国乃至全球算力调度的核心节点。
- ❑ 其次，凤凰城、亚特兰大和达拉斯具备稳定能源供应、政策支持和土地优势，成为新兴的算力扩张热点区域。芝加哥、北加州等传统中心依然保有较强规模，但受到能源成本、空间资源等因素影响，增长相对平缓。


AIDC全球版图深度研究——美国算力建设现状（2/2）

美国算力建设正呈现“规模下沉、控制集中”的格局，二级与新兴市场蕴含增长潜力，而科技巨头通过持续高强度资本支出加速主导全球算力资源布局

美国算力资源建设现状

二级市场	规模（MW）	控制率
奥斯汀/圣安东尼奥，德克萨斯州	750	2.80%
波士顿，马萨诸塞州	90	12.00%
丹佛，科罗拉多州	130	22.00%
海罗斯，俄勒冈州	575	0.48%
休斯顿，德克萨斯州	210	6.80%
洛杉矶，加利福尼亚	230	5.06%
盐湖城，犹他州	360	0.30%
三州（摩涅狄格州、纽约州、新泽西州北部）	510	3.80%

新兴市场	规模（MW）	控制率
哥伦布，俄亥俄州	510	1.00%
雷诺，内华达州	544	0.60%




- ❑ 在二级市场中，部分地区如丹佛和波士顿尽管规模较小，但具备相对较高的资源控制力，显示出本地运营商或早期布局者的竞争优势；而奥斯汀/圣安东尼奥和海罗斯等地区虽然算力规模较大，但控制率不足3%，表明资源分散或外来资本尚未形成规模主导。相比之下，新兴市场如哥伦布和雷诺的规模已接近成熟市场水平，但控制率仍不足1%，反映出当前处于资源导入期，尚未形成垄断格局，市场潜力巨大但竞争格局未定。
- ❑ 从资本投入趋势看，2025年亚马逊、谷歌和微软三大超大规模企业计划持续加码资本支出，显示其在AI训练、云服务和数据中心等核心领域的战略延展。


AIDC全球版图深度研究——欧洲算力建设现状

欧洲数据中心建设呈现出“核心集中、边缘扩张”的特征。以英国、荷兰和法国为代表的西欧国家构成数据中心核心集群， 其中英国遥遥领先， 占据欧洲市场主导地位

欧洲算力资源建设现状



超级计算机	算力（Pflop/s）
MELUXINA supercomputer	12.81
KAROLINA supercomputer	9.59
DEUCALION supercomputer	7.22
HPC Vega IZUM	6.92
DISCOVERER supercomputer	4.51



- 欧洲数据中心的地域分布展现出明显的层级结构与发展梯度：以英国为首，荷兰与法国紧随其后，构成欧洲数据中心的第一梯队，集中体现了西欧国家在数字基础设施建设、网络互联性、政策支持及市场成熟度方面的领先地位。
- 英国凭借其全球金融中心地位、丰富的光缆资源与开放的数据政策，占据压倒性领先，成为欧洲乃至全球的数据枢纽之一。
- 第二梯队包括俄罗斯、波兰、意大利、西班牙等国家。这些国家虽然在总量上落后于西欧，但近年来在数据中心投资规模、外资引入力度以及本地数字化转型方面增长显著，尤其是波兰和俄罗斯，受益于地理位置优越、劳动力成本相对较低，逐步成为国际云计算服务商的重要选址备选。

来源：专家访谈，头豹研究院

AIDC全球版图深度研究——亚太算力建设现状

亚太地区算力资源建设加速推进，中国大陆引领区域发展，各国数据中心规模持续扩张，呈现出集中化与多元化并存的格局

亚太算力资源建设现状


■ 亚太数据中心市场规模

单位：KMW




■ 亚太数据中心机架规模

单位：个



■ 各国市场数据中心数量 单位：座





- 亚太地区算力资源建设正在快速推进。预计到2029年，亚太数据中心市场规模将达到23.20 KMW，较2024年的14.27 KMW增长超过60%。与此同时，2024年亚太地区的数据中心机架规模已达269.48万个，表明算力基础设施在容量和密度方面已具备相当规模，为区域内各国数字化转型奠定了坚实基础。
- 在各国数据中心建设方面，中国大陆处于绝对领先地位，数据中心数量接近450座，显著高于亚太其他国家和地区，凸显其在区域数字基础设施布局中的核心地位。澳大利亚、日本和印度分列其后，反映出这些国家在区域内具备较强的算力支撑能力。新加坡、中国香港、新西兰等国家和地区尽管国土面积有限，但也保持了相对较高的数据中心密度，体现出其在区域数据交换和跨境服务中的枢纽角色。

AIDC全球版图深度研究——拉美算力建设现状

拉美算力基础设施加速扩张，以巴西为核心的区域布局逐步成型，支撑数据中心市场营收持续增长，正迈向高密度、高容量、高投资的新兴战略枢纽

拉美算力资源建设现状




- 拉丁美洲算力资源建设呈现快速扩张态势，整体市场正在步入增长快车道。当前已建数据中心达230座，另有87座即将建成，显示出区域内对数字基础设施的持续投入和重视。
- 巴西作为区域主导国，拥有最多的数据中心数量，占据拉美数据中心市场的核心地位，并承担着未来新增电力容量的一半以上，奠定其在新兴算力市场中的引领作用。
- 营收方面，数据中心市场预计从2023年的3,100亿美元增长至2030年的6,300亿美元，2027年后年增长率维持在9%左右，展现出强劲的市场动能。未来，除巴西外，阿根廷、秘鲁、巴拉圭等国也将成为新兴的数据中心布局重点，预计到2030年，拉美市场将吸引到更多的新投资，助推区域算力基础设施迈入新阶段。

来源：专家访谈，头豹研究院

AIDC全球版图深度研究——中东算力建设现状


中东地区算力建设加速发展，以沙特和阿联酋为核心的国家正推动数据中心由在用向在建快速扩展，主要城市的数据中心容量构成呈现以零售型colo为主、批发型和自建协同发展的多元化格局

中东算力资源建设现状



- 中东地区数据中心市场规模预计将在2024年1.03 KMW的基础上于2029年增至2.06 KMW。在数据中心建设方面，沙特和阿联酋是区域核心，两国在建与在用容量均处于领先地位，其中沙特建设体量最大，展现出未来主导能力，而阿联酋则以较高的在用比重反映出其运营成熟度。
- 在用数据中心的容量结构也呈现出明显的城市差异：迪拜以批发型colo为主，强调规模化服务输出；阿布扎比则有较高比例的自建资源，体现本地政府和企业对自主可控的算力掌控力；而利雅得、特拉维夫和多哈则以零售型colo为主，显示出市场化、分布式服务模式的兴起。整体来看，中东算力基础设施正由核心国家向周边辐射、由大规模建设向差异化运营转型，成为全球算力版图中不可忽视的新兴力量。

□ 中东主要城市的在用数据中心容量构成



头豹业务合作

会员账号

可阅读全部原创报告和百万数据，提供PC及移动端，方便触达平台内容

定制报告/词条

行企研究多模态搜索引擎及数据库，募投可研、尽调、IRPR等研究咨询

定制白皮书

对产业及细分行业进行现状梳理和趋势洞察，输出全局观深度研究报告

报告作者



袁栩聪
首席分析师



王利华
行业分析师

• service@leadleo.com

招股书引用

研究覆盖国民经济19+核心产业，内容可授权引用至上市文件、年报

市场地位确认

对客户竞争优势进行评估和证明，助力企业价值提升及品牌影响力传播

行研训练营

依托完善行业研究体系，帮助学生掌握行业研究能力，丰富简历履历

业务咨询

- 客服电话：400-072-5588
- 官方网站：www.leadleo.com

深圳办公室

广东省深圳市南山区粤海街道
华润置地大厦E座4105室

邮编：518057

上海办公室

上海市静安区南京西1717号
会德丰国际广场 2701室

邮编：200040

南京办公室

江苏省南京市栖霞区经济开发
区兴智科技园B栋401

邮编：210046

方法论

- ◆ 头豹研究院布局中国市场，深入研究19大行业，532个垂直行业的市场变化，已经积累了近100万行业研究样本，完成近10,000多个独立的研究咨询项目。
- ◆ 研究院依托中国活跃的经济环境，研究内容覆盖整个行业的发展周期，伴随着行业中企业的创立，发展，扩张，到企业走向上市及上市后的成熟期，研究院的各行业研究员探索和评估行业中多变的产业模式，企业的商业模式和运营模式，以专业的视野解读行业的沿革。
- ◆ 研究院融合传统与新型的研究方法，采用自主研发的算法，结合行业交叉的大数据，以多元化的调研方法，挖掘定量数据背后的逻辑，分析定性内容背后的观点，客观和真实地阐述行业的现状，前瞻性地预测行业未来的发展趋势，在研究院的每一份研究报告中，完整地呈现行业的过去，现在和未来。
- ◆ 研究院密切关注行业发展最新动向，报告内容及数据会随着行业发展、技术革新、竞争格局变化、政策法规颁布、市场调研深入，保持不断更新与优化。
- ◆ 研究院秉承匠心研究，砥砺前行的宗旨，从战略的角度分析行业，从执行的层面阅读行业，为每一个行业的报告阅读者提供值得品鉴的研究报告。

法律声明

- ◆ 本报告著作权归头豹所有，未经书面许可，任何机构或个人不得以任何形式翻版、复刻、发表或引用。若征得头豹同意进行引用、刊发的，需在允许的范围内使用，并注明出处为“头豹研究院”，且不得对本报告进行任何有悖原意的引用、删节或修改。
- ◆ 本报告分析师具有专业研究能力，保证报告数据均来自合法合规渠道，观点产出及数据分析基于分析师对行业的客观理解，本报告不受任何第三方授意或影响。
- ◆ 本报告所涉及的观点或信息仅供参考，不构成任何证券或基金投资建议。本报告仅在相关法律许可的情况下发放，并仅为提供信息而发放，概不构成任何广告或证券研究报告。在法律许可的情况下，头豹可能会为报告中提及的企业提供或争取提供投融资或咨询等相关服务。
- ◆ 本报告的部分信息来源于公开资料，头豹对该等信息的准确性、完整性或可靠性不做任何保证。本报告所载的资料、意见及推测仅反映头豹于发布本报告当日的判断，过往报告中的描述不应作为日后的表现依据。在不同时期，头豹可发出与本报告所载资料、意见及推测不一致的报告或文章。头豹均不保证本报告所含信息保持在最新状态。同时，头豹对本报告所含信息可在不发出通知的情形下做出修改，读者应当自行关注相应的更新或修改。任何机构或个人应对其利用本报告的数据、分析、研究、部分或者全部内容所进行的一切活动负责并承担该等活动所导致的任何损失或伤害。

FROST & SULLIVAN

沙利文



NIE

2025沙利文新投资大会

第十九届沙利文全球增长、科创与领导力峰会 暨第四届新投资大会

THE 19TH FROST & SULLIVAN GLOBAL GROWTH, INNOVATION
AND LEADERSHIP SUMMIT AND THE 4TH NEW INVESTMENT EVENT

2025.08.27-08.28 中国·上海 SHANGHAI·CHINA

- ESG与新质生产力高峰论坛
 - 智能制造出海分论坛
 - 生命科学新投资高峰论坛
 - 上市公司高质量发展论坛
 - AI进化论-智能生态安全架构与可持续发展论坛
 - 新消费趋势展望论坛
- (更多信息请关注弗若斯特沙利文官网)